

Parcial

Curso: Estadística III

Docente: Daniel Betancur Trujillo

Política de uso de inteligencia artificial:

Este parcial evalúa el criterio del estudiante, no la capacidad de obtener texto de un asistente automático. Se permite el uso de herramientas de inteligencia artificial únicamente como apoyo puntual para consultar sintaxis o depurar errores de código, y siempre que se declare en el documento entregado (herramienta usada y para qué punto).

No se permite, en ningún caso:

- Generar con inteligencia artificial el documento de entrega, el protocolo previo, las justificaciones o las conclusiones. Estos textos deben ser redactados por el equipo.
- Entregar código o análisis que el equipo no sea capaz de explicar línea por línea durante la sustentación.
- Omitir la declaración de uso cuando la herramienta sí se utilizó.

Consecuencias: la detección de un documento generado por inteligencia artificial, o la imposibilidad de explicar el contenido entregado, anula la nota del componente correspondiente. Si afecta la totalidad del trabajo, el parcial se califica en cero y se reporta como falta de honestidad académica según el reglamento estudiantil. La sustentación oral es el mecanismo principal de verificación: las preguntas del banco que aparece al final de este documento se responden sin apoyo de notas ni de dispositivos.

Instrucciones:

1. Escoge un conjunto de datos que contenga al menos 20 variables combinadas entre categóricas y numéricas (no se consideran los datos de tipo identificador) y 1000 registros. Se recomienda utilizar alguno de los siguientes repositorios:
 - [Tableau Public Datasets](#)
 - [Kaggle Datasets](#)
 - [Maven Analytics Data Playground](#)
2. Carga del dataset
 - Importar librerías (pandas, numpy).
 - Cargar el dataset y mostrar las primeras filas (`.head()`).
3. Exploración inicial
 - Revisar la estructura: número de filas, columnas y tipos de datos (`.info()`).

- Identificar valores nulos y duplicados(*.isnull()*, *.duplicated()*).
 - Resumen descriptivo de los datos (*.describe()*).
4. Protocolo previo de limpieza (se entrega y se congela antes de modificar los datos)
- Redactar, en máximo una página, las reglas que el equipo aplicará ANTES de ver el resultado de aplicarlas. El protocolo debe fijar, como mínimo:
 - ✓ Umbral de eliminación de columnas por porcentaje de faltantes y su justificación.
 - ✓ Criterio de imputación por tipo de variable (numérica simétrica, numérica asimétrica, categórica), decidido de antemano.
 - ✓ Criterio de detección de atípicos (método y parámetro: k desviaciones estándar, factor del rango intercuartílico) y regla de acción asociada.
 - ✓ Política frente a los duplicados: qué combinación de columnas define un duplicado real.
 - Este documento se entrega firmado por el equipo antes de ejecutar la limpieza y no puede modificarse después.
 - Al final del trabajo se reporta, punto por punto, en qué se desviaron del protocolo, qué evidencia los obligó a desviarse y qué habría pasado si hubieran sostenido la regla original. Desviarse no penaliza; desviarse sin justificar sí.
5. Manejo de valores nulos
- Detectar las columnas que tienen más del 50% de valores faltantes y borrarlas.
 - Para el resto de los datos faltantes aplicar alguna o varias de las siguientes estrategias y justificarlas:
 - ✓ Eliminar registros incompletos.
 - ✓ Imputar (reemplazar) con la media, mediana o moda de la variable.
 - ✓ Sustituir por un valor específico (ej. “Desconocido”).
 - ✓ Usar una regla de asociación.
6. Cuantificación del sesgo introducido por la imputación
- Para cada variable numérica imputada, reportar en una tabla la media, la mediana, la desviación estándar y el número de observaciones, antes y después de imputar.
 - Graficar el histograma o la densidad de la variable antes y después, superpuestos en la misma figura.
 - Para al menos una variable, comparar dos estrategias distintas de imputación sobre la misma columna y argumentar cuál se conserva y por qué.
7. Tratamiento de duplicados: Identificar filas repetidas decidir si eliminarlas o mantenerlas, justificar.
8. Corrección de tipos de datos
- Unifica formatos en nombres, fechas y categorías.
 - ✓ Verificar que las variables numéricas no estén en formato de texto.
 - ✓ Verifica que las fechas estén en un solo formato (se recomienda usar %Y-%m-%d %H:%M:%S).

9. Normalización de valores categóricos

- Revisar inconsistencias en texto (ej. "Femenino", "femenino", "H").
- Estandarizar categorías (ej. todo en minúscula).
- Buscar y corregir errores por uso de caracteres especiales o malas digitaciones.

10. Tratamiento de valores atípicos (outliers) en variables numéricas:

- Detectar los valores extremos con un método estadístico explícito (cuartiles con factor 1.5 del rango intercuartílico, o k desviaciones estándar), declarando el parámetro usado.
- Clasificar cada grupo de atípicos detectados en una de estas cuatro categorías, y sustentar la clasificación con evidencia del propio dataset:
 - ✓ Error de digitación (por ejemplo, un dígito de más).
 - ✓ Error de unidad o de escala (metros registrados como centímetros, precios en otra moneda).
 - ✓ Observación válida extrema (el valor es real y pertenece a la población estudiada).
 - ✓ Subpoblación distinta (los valores extremos forman un grupo con comportamiento propio).
 - ✓ Observación contaminante: una observación que no proviene de la población que se está estudiando
- La acción debe seguir a la clasificación, no al revés: corregir, imputar, conservar, o separar el subgrupo. Eliminar es la última opción y exige justificación.
- Obligatorio: presentar al menos un caso en el que el método estadístico marcó como atípico un valor que NO debe eliminarse, y explicar por qué el método falló en ese caso.
- Reportar cuántos registros habrían perdido si hubieran eliminado todos los atípicos detectados, en número y en porcentaje del total.

11. Validación de la coherencia de los datos:

- Verifica que los datos sigan reglas lógicas y restricciones conocidas. Por ejemplo, asegúrate de que las fechas de nacimiento sean anteriores a las fechas de registro.
- Comprueba la consistencia entre diferentes columnas. Por ejemplo, si tienes columnas de "país" y "código postal", asegúrate de que los códigos postales coincidan con los países correspondientes.
- Verificar valores máximos y mínimos para variables numéricas

12. Reproducibilidad y validación programática del resultado

- El código debe ejecutarse de principio a fin, partiendo del archivo original sin modificar y sin errores.
- Fijar la semilla aleatoria en toda operación que use azar, de modo que dos ejecuciones produzcan un dataset final idéntico.
- No sobrescribir el archivo original: la limpieza produce un archivo nuevo.

13. Creación de variables derivadas (opcional)

Entrega:

Protocolo previo de limpieza se entrega el martes 15 de septiembre de 2026.

El equipo entrega, en un único archivo comprimido:

- El código ejecutado
- Declaración de uso de herramientas de inteligencia artificial al inicio.
- El dataset original sin modificar y el dataset final limpio.

Sustentación:

Presentación de 10 minutos donde expliquen:

1. Qué encontraron en cada punto
2. Justificación de las decisiones tomadas
3. ¿Qué problemáticas se les presentaron y como lo solucionaron?
4. Comparación del dataset inicial vs el dataset final
5. Desviaciones respecto al protocolo previo y la evidencia que las motivó.
6. Una decisión de limpieza que hoy consideran equivocada, y qué harían distinto.

A los 10 minutos de exposición se suman 5 minutos de preguntas. El docente escoge al azar dos preguntas del banco que aparece a continuación y designa quién del equipo responde cada una. Se responde sin notas, sin diapositivas y sin dispositivos. La incapacidad de sustentar el trabajo entregado invalida la nota, con independencia de la calidad del documento.

Nota: La sustentación la hace solo 1 persona del equipo seleccionada al azar

Banco de preguntas para la sustentación

Las siguientes preguntas te ayudaran a prepararte para la sustentación.

A. Sobre el protocolo y las decisiones tomadas

P1. Muéstreme un punto en el que se desviaron del protocolo previo. ¿Qué evidencia los obligó a hacerlo?

P2. ¿Qué habría pasado con el dataset final si hubieran sostenido la regla original del protocolo en ese punto?

P3. Si otro equipo tomara su dataset crudo y su protocolo, ¿llegaría exactamente al mismo resultado? ¿Dónde no, y por qué?

P4. ¿Cuál de sus decisiones de limpieza es la más discutible? Defiéndala.

P5. Nombre una decisión que hoy considera equivocada y explique qué haría distinto.

P6. ¿Qué información se perdió irreversiblemente en su proceso de limpieza?

B. Sobre valores faltantes e imputación

P7. ¿Por qué eligió ese umbral para eliminar columnas y no uno mayor o menor?

P8. Tome la columna con más faltantes: ¿los datos faltan al azar o el hecho de faltar depende de otra variable? ¿Con qué evidencia lo afirma?

P9. Si el faltante NO es aleatorio, ¿qué le hace su imputación al análisis posterior?

P10. Imputó con la media en esta columna. ¿Qué le pasó a la desviación estándar? ¿Por qué?

P11. ¿En qué caso preferiría la mediana sobre la media, y qué característica de la variable se lo indica?

P12. ¿Por qué imputar puede ser peor que eliminar el registro? Dé un caso de su propio dataset.

P13. ¿Qué correlación cambió más tras la imputación y cómo lo interpreta?

P14. Si le pidiera reportar la incertidumbre que introdujo al imputar, ¿cómo lo haría?

C. Sobre valores atípicos

P15. ¿Qué método y qué parámetro usó para detectar atípicos, y por qué ese y no otro?

P16. Muéstreme el atípico que decidió conservar. ¿Por qué el método lo marcó y por qué el método se equivocó?

P17. ¿Cómo distinguió un error de digitación de una observación válida extrema?

P18. Si los atípicos forman una subpoblación, ¿eliminarlos qué le hace a la conclusión del estudio?

P19. ¿Qué porcentaje de registros habría perdido eliminando todos los atípicos detectados? ¿Le parece aceptable?

P20. Su variable es fuertemente asimétrica. ¿Siguiendo siendo válido el criterio de las k desviaciones estándar? Justifique.

P21. ¿Puede un valor ser atípico en una variable y perfectamente normal al mirar dos variables a la vez? Dé un ejemplo.

D. Sobre duplicados, tipos y categorías

P22. ¿Qué combinación de columnas define un duplicado real en su dataset? ¿Por qué esa y no el registro completo?

P23. ¿Encontró duplicados parciales, es decir, el mismo caso con datos distintos? ¿Con cuál se quedó y por qué?

P24. ¿Qué habría pasado si no hubiera eliminado los duplicados?

P25. Al estandarizar categorías a minúsculas, ¿fusionó categorías que en realidad eran distintas? ¿Cómo lo verificó?

P26. ¿Cómo trató las tildes y los caracteres especiales, y qué riesgo tiene la decisión que tomó?

P27. Una variable numérica venía como texto. ¿Por qué venía así y qué encontró al intentar convertirla?

P28. ¿Cómo resolvió las fechas ambiguas del tipo 03/04/2024?

F. Sobre el código y la reproducibilidad

P29. Abra el código y ejecútelo desde cero delante de nosotros.

P30. Explíqueme qué hace esta línea de código que señalo, y por qué está escrita así y no de otra forma.

P31. ¿Por qué usó este método de pandas y no este otro que hace algo parecido?

P32. Si mañana llega el mismo dataset con 500 registros nuevos, ¿su código funciona sin tocar nada? ¿Dónde se rompería?

P33. ¿Qué parte del código escribió cada integrante del equipo?

P34. ¿En qué punto usó una herramienta de inteligencia artificial y qué le pidió exactamente? Muéstreme qué cambió usted de lo que le entregó.

P35. Reescriba en el tablero, sin ayuda, la instrucción que resuelve el punto de tratamiento de nulos.

G. Comprensión general

- P36.** En una frase: ¿qué problema tenía este dataset que lo hacía inutilizable, y qué lo hace utilizable ahora?
- P37.** ¿Su limpieza mejoró los datos o los volvió más convenientes para lo que querían mostrar?
- P38.** Si tuviera el doble de tiempo, ¿en qué lo invertiría?
- P39.** ¿Qué aprendió en este parcial que no sabía antes de empezar?
- P40.** ¿Su dataset final está limpio o solo cumple las reglas que ustedes escribieron?
¿Cuál es la diferencia?