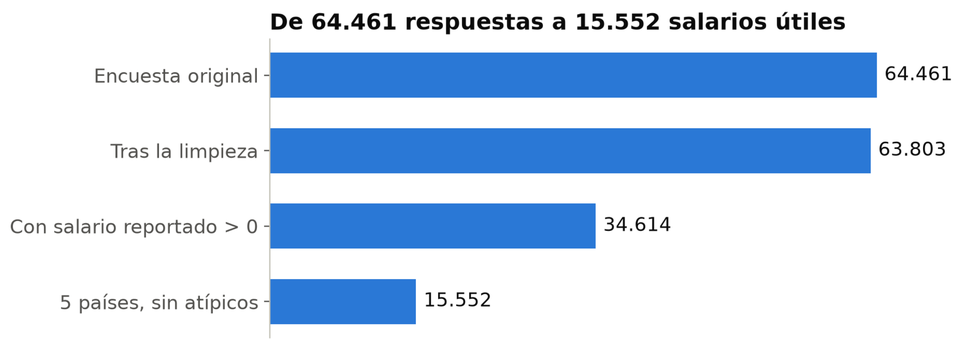
¿Qué explica el salario de un programador? Cinco redes neuronales por país

Daniel Puerta Bernal · Juan Diego Guzmán · Tomás Marín | Docente: Daniel Betancur Trujillo | Estadística III · 2026-2

INTRODUCCIÓN

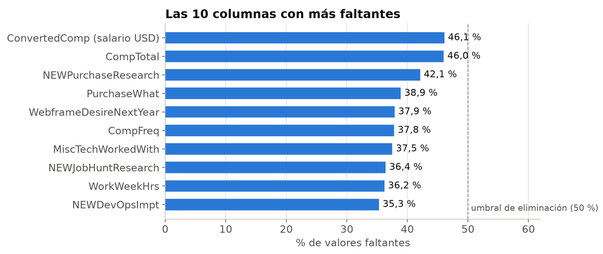
Si se mezclan todos los países, el país explica casi todo el salario y tapa las diferencias entre programadores. **Objetivo:** entrenar una red neuronal de regresión por país (los 5 con más datos) sobre la encuesta Stack Overflow 2020 para estimar el salario anual en USD y comparar qué lo explica en cada país.

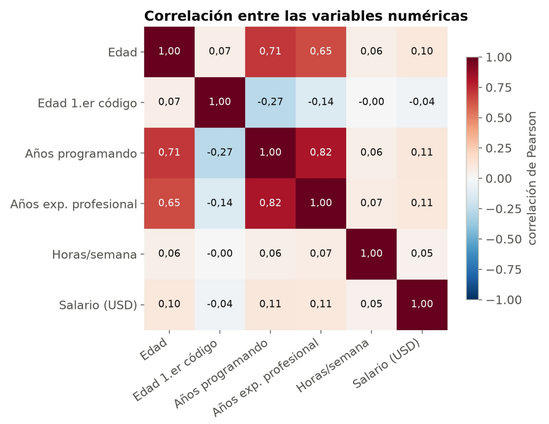


METODOLOGÍA

1 · Limpieza y EDA

64.461 × 61 → **63.803 × 114**. Nulos numéricos con la **mediana** (todas asimétricas, |sesgo| > 0,5); categóricos como «Desconocido»; **658 duplicados** fuera; atípicos tratados caso a caso con el RIC (ej. 375 h/semana = 37,5 con la coma perdida).

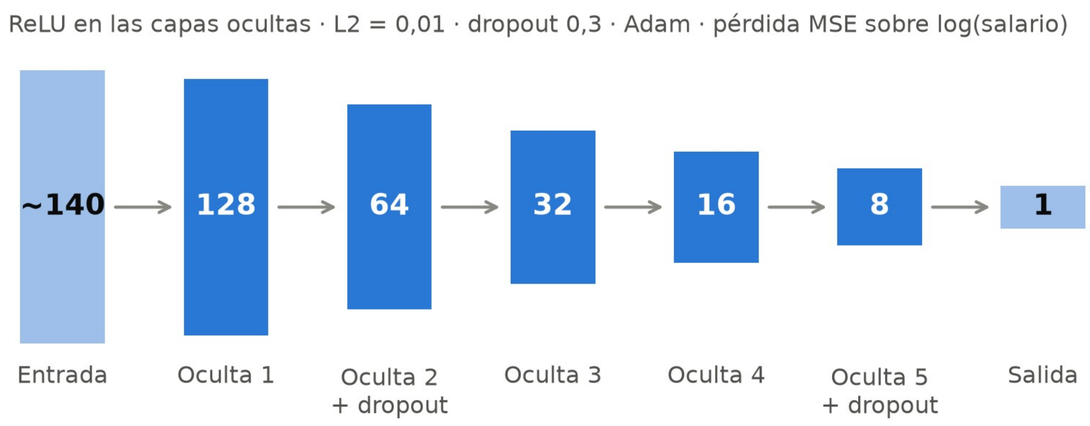




2 · Preparación

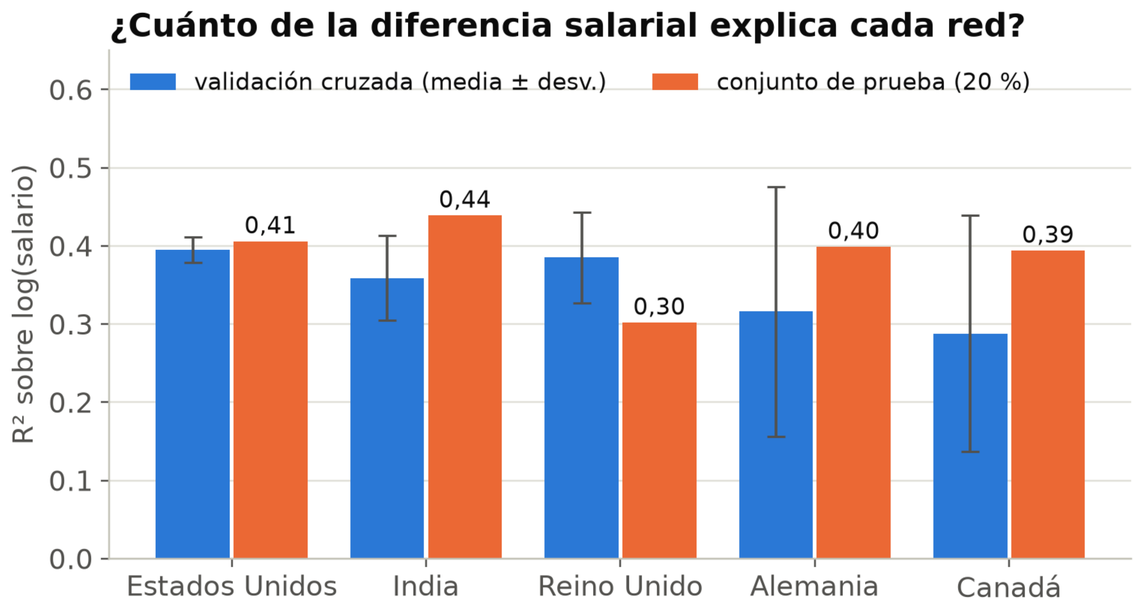
Solo salarios reportados > 0; se modela **log(salario)** por su cola larga. Atípicos por país con la **regla de Tukey**. Partición **70/10/20** (entrenamiento / validación / prueba). One-hot para categóricas, estandarización para numéricas y **12 grupos de variables** elegidos por cuánto suben el R^2.

3 · Modelo: red feedforward de 5 capas ocultas



Early stopping (paciencia 20, máx. 300 épocas, lote 32). Se compararon **6 arquitecturas** + **Ridge** con validación cruzada de 5 pliegues.

RESULTADOS

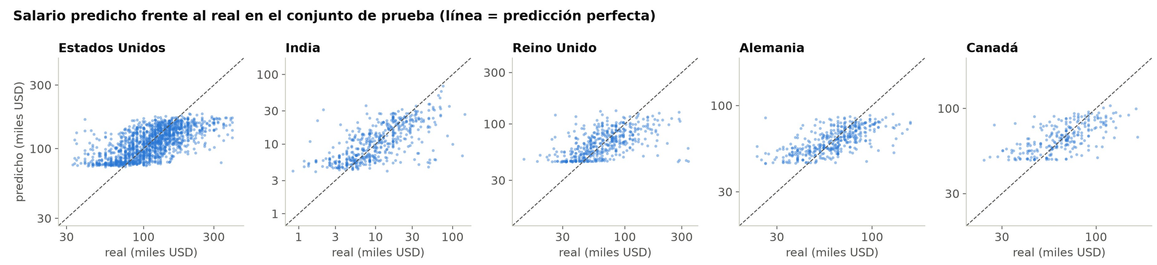




R^2 0,29–0,41: la red explica cerca del **40 %** de la diferencia salarial dentro de cada país.

Error 18–29 % menor que predecir la mediana (MAE en USD).

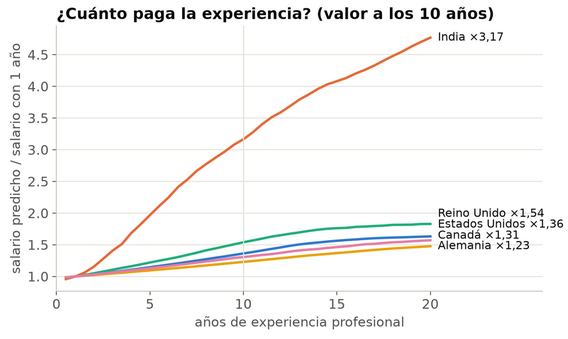
La **experiencia** es la variable n.º 1 en los 5 países.



Las predicciones se «aplanan» hacia la media: la red subestima los salarios altos y sobreestima los bajos.

CONCLUSIONES

- Una red por país evita que el país «tape» todo: dentro de un país el perfil explica ~**30–40 %** del salario.
- La **experiencia** domina en todos; después pesan el **tamaño de la empresa** y el **tipo de desarrollador**.
- En India 10 años de experiencia multiplican el salario por **3,2**; en EE. UU. y Alemania solo por 1,2–1,4.
- La red de 5 capas **no supera** a la de 3 capas con L2 ni a Ridge: con 870–5.200 personas por país, la profundidad aporta poco.



REFERENCIAS

Stack Overflow. (2020). Developer Survey 2020 [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/palvinder2006/stackoverflow · Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. JMLR, 12, 2825–2830. · TensorFlow. (2025). Keras [Software]. https://www.tensorflow.org/guide/keras