

Calculadora de salarios con redes neuronales

Sustentación · Estadística III

Daniel Puerta Bernal · Juan Diego Guzmán · Tomás Marín | Estadística III

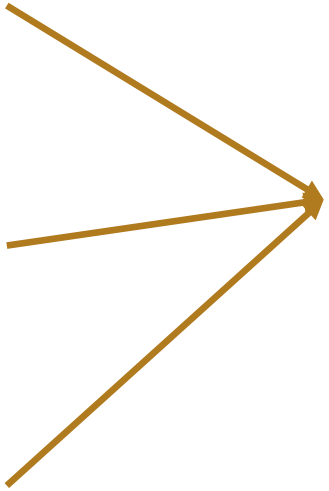
¿Cuánto gana un programador?

Objetivo: explicar por qué unos programadores ganan más que otros dentro de un mismo país, con una red neuronal por país, sobre la encuesta Stack Overflow 2020.

Perfil técnico
lenguajes, tipo de desarrollador, plataformas, bases de datos y frameworks

Experiencia y trabajo
años de experiencia, horas por semana, tipo de empleo y tamaño de la empresa

Formación y entorno
nivel de estudios, carrera universitaria y sistema operativo



5 redes neuronales, una por país

Salario anual estimado (USD)

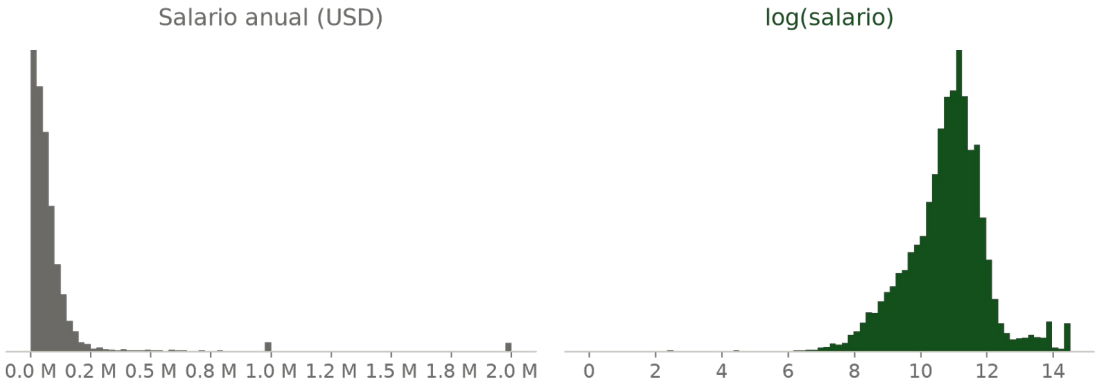
Regresión: la salida es un número continuo. Después se comparan los 5 países con los resultados de sus redes.

De 63.803 respuestas a 15.552 salarios

63.803
respuestas en el dataset limpio del parcial

34.614
con salario reportado de verdad y mayor que 0 (se quitan 29.189 imputados o en 0)

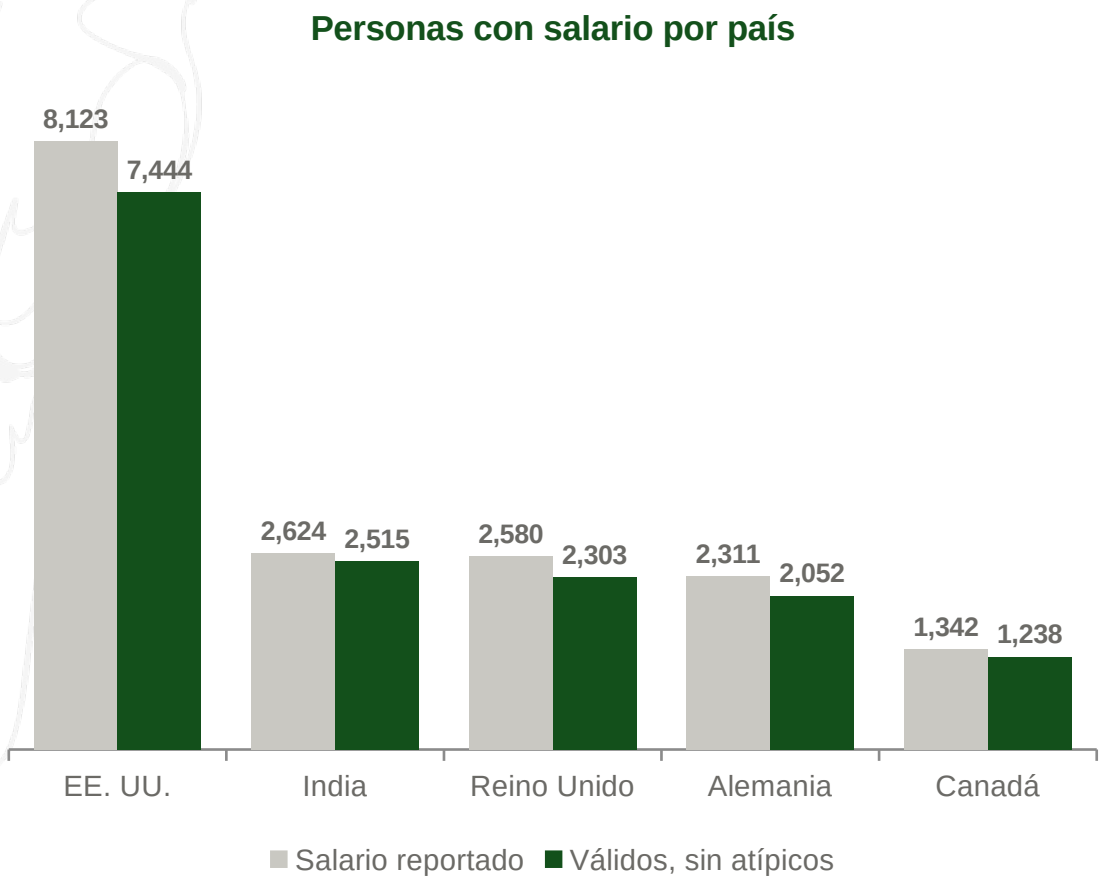
15.552
en los 5 países con más datos, sin atípicos (regla de Tukey por país: se quitan 1.428)



El salario tiene una cola larga: unos pocos salarios enormes dominarían el error.

Su logaritmo se concentra, así que la red aprende log(salario) y la calculadora devuelve e^(predicción) en dólares.

¿Cuántos datos tiene cada país?



Cómo se reparten

70 % entrenamiento, 10 % validación y 20 % prueba. EE. UU. entrena con 5.210 personas; Canadá con 866.

Cómo se limpian

La regla de Tukey quita entre el 4 % (India) y el 11 % (Alemania): salarios imposibles para ese país.

Menos datos, menos estable

El R^2 varía ±0,016 entre pliegues en EE. UU. y ±0,15–0,16 en Alemania y Canadá.

¿Y con más datos?

Una red más grande podría aprovecharlos sin memorizar. Con pocos, una regresión lineal rinde igual o mejor.

¿Qué es una red neuronal?

Un modelo organizado en capas: una capa de entrada con los datos, capas ocultas donde ocurre el aprendizaje y una capa de salida con la respuesta. Aprende relaciones **no lineales** que una regresión lineal no captura: el salario sube rápido los primeros años y luego se aplana, y el efecto de la experiencia cambia según la empresa.

01

Recomendaciones

Netflix, Spotify y Amazon predicen qué contenido o producto te va a gustar a partir de tu historial.

02

Detección de fraude

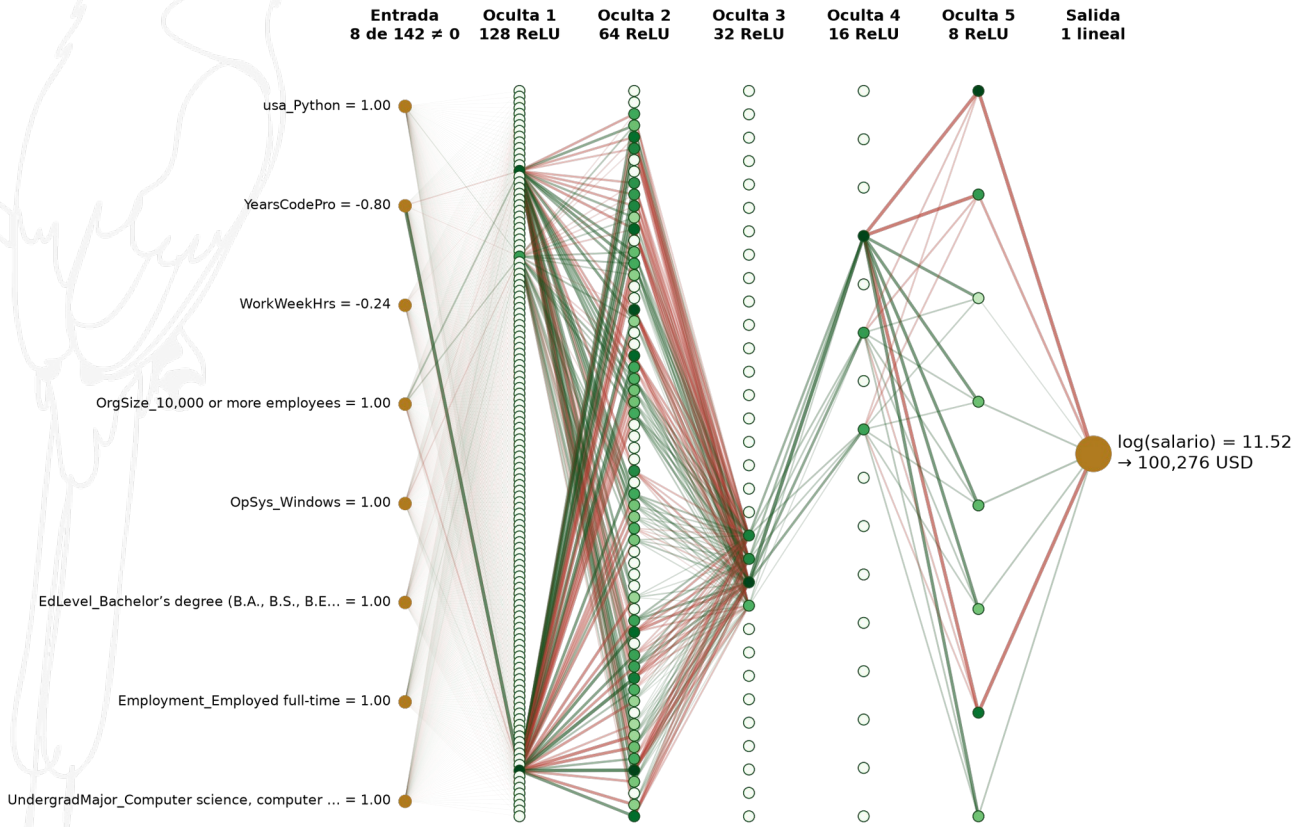
Los bancos aprenden el comportamiento normal de cada cliente y marcan en tiempo real las transacciones sospechosas.

03

Estimación salarial

LinkedIn y Glassdoor estiman rangos de salario según el perfil: el mismo tipo de problema que resolvemos aquí.

Nuestra red: 5 capas ocultas



Entrada · 142 valores (EE. UU.)

Lenguajes, plataformas, bases de datos… (0/1), empresa y estudios (one-hot), experiencia y horas estandarizadas.

5 capas ocultas · 128, 64, 32, 16, 8

ReLU y L2 en todas; dropout 0,3 tras la 2.ª y la 5.ª. Verde intenso = más activación.

Salida · 1 neurona

Lineal: da log(salario). Python, 3 años, EE. UU. → e^11,52 = 100.276 USD.

29.313 pesos y sesgos aprendidos (red de EE. UU.)

Cómo calcula cada neurona

1 · Suma ponderada

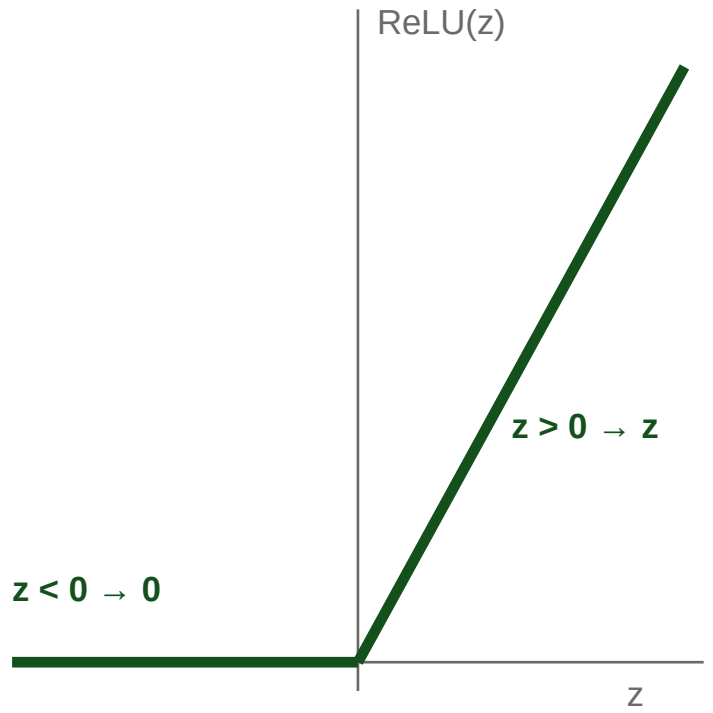
$$z = w_1x_1 + w_2x_2 + \ldots + w_nx_n + b$$

Cada neurona combina las salidas de la capa anterior con sus pesos w y le suma un sesgo b. Los pesos y el sesgo son lo que la red aprende.

2 · Función de activación ReLU

$$\mathrm{ReLU}(z) = \max(0, z)$$

Deja pasar los valores positivos y convierte los negativos en 0. Esa no linealidad es lo que le permite aprender curvas que una recta no puede.



Cómo aprende la red

3 · Función de costo (MSE) $MSE = (1/n)\ \Sigma\ (y_i - \hat{y}_i)^2$

Mide qué tan lejos están las predicciones del valor real; al elevar al cuadrado castiga más los errores grandes.

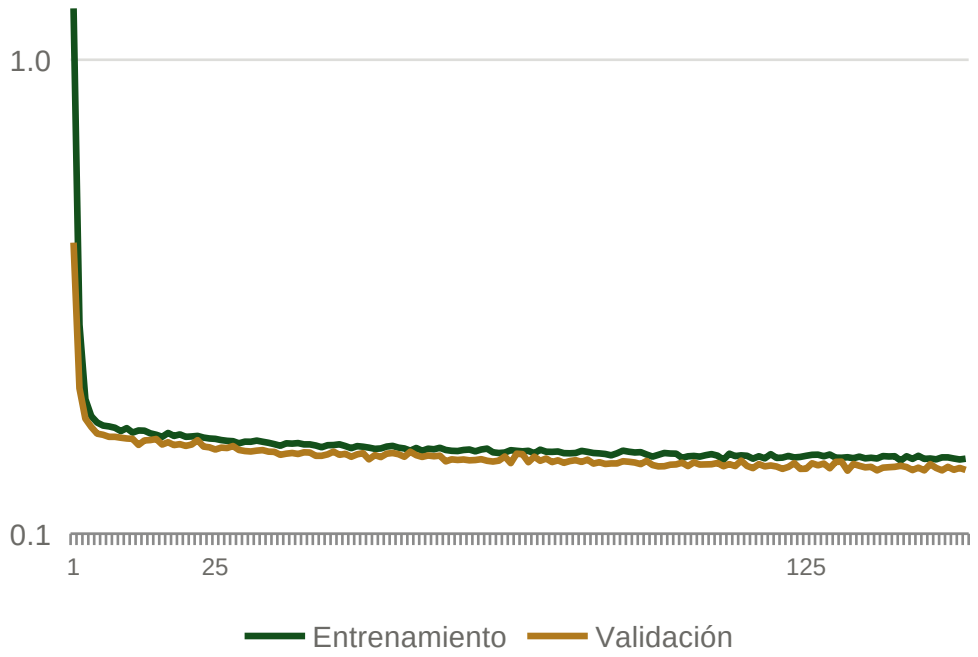
4 · Backpropagation $\partial MSE / \partial w$

Con la regla de la cadena calcula cuánto contribuye cada peso al error, de la salida hacia atrás.

5 · Descenso de gradiente $w \leftarrow w - \eta \cdot \partial MSE / \partial w$

Corrige cada peso un paso pequeño (η = 0,001, Adam), lote a lote. L2 frena los pesos grandes y el dropout apaga neuronas al azar.

Error (MSE + L2) por época · EE. UU. · escala log



Early stopping: mejor época 132 de 152 (red de EE. UU.)

El entrenamiento de cada red

Cuántas épocas

EE. UU. 152 (mejor 132) · India 37 (17) · Reino Unido 53 (33) · Alemania 223 (203) · Canadá 118 (98).

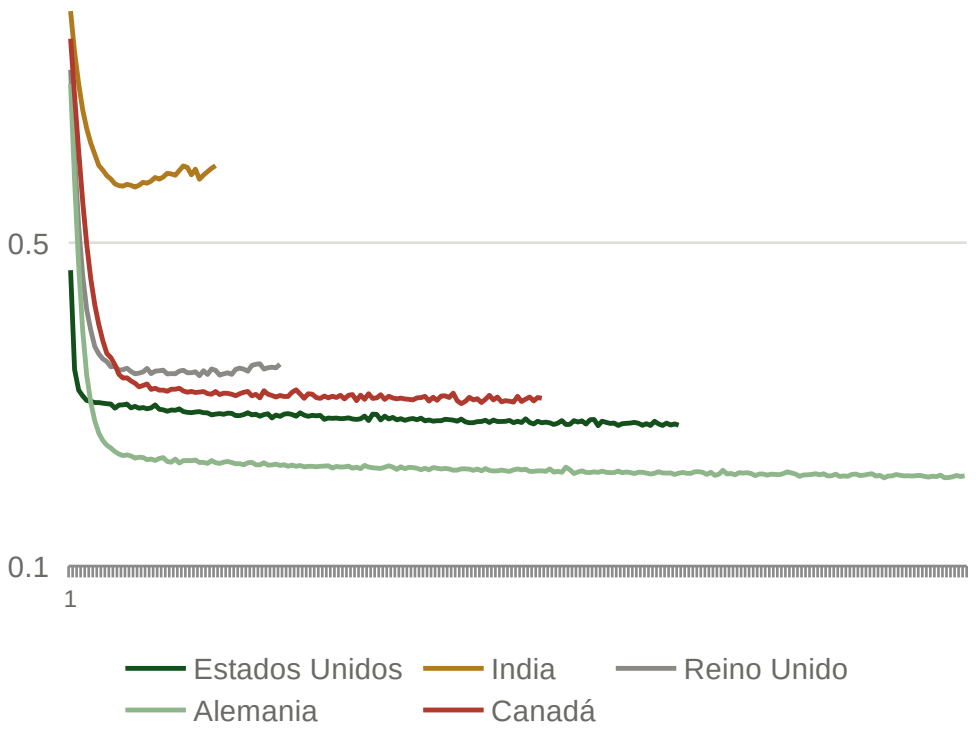
India y Reino Unido paran pronto

Su error en validación deja de bajar antes de la época 35: el early stopping corta a las 20 épocas sin mejora.

La misma receta en las 5

Adam (η = 0,001), lotes de 32, L2 y dropout iguales: solo cambian los datos de cada país.

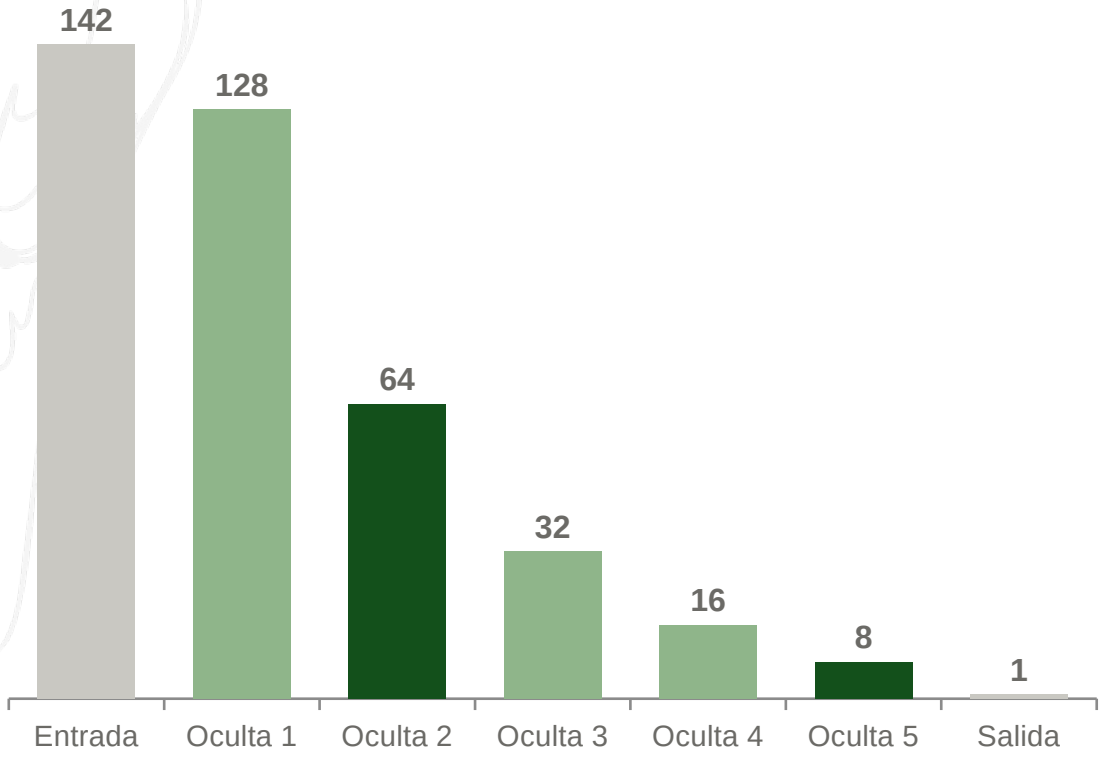
Error en validación por época · escala log



Entre paréntesis: la mejor época, la de menor error en validación.

¿Por qué 128 → 64 → 32 → 16 → 8?

Neuronas por capa · verde oscuro = con dropout



Empieza en 128

Casi tantas neuronas como entradas (142): la primera capa no pierde información.

Se reduce a la mitad

Cada capa resume la anterior en menos patrones, hasta llegar a 1 salario. Potencias de 2 por convención.

¿Por qué no más?

Ya son 29.313 pesos para 870–5.200 personas por país. La red ancha de 3 capas (128, 64, 32) no mejoró: 0,366.

¿Por qué no menos?

La versión angosta (64, 32, 32, 16, 16) dejó de aprender en Alemania: R^2 0,17.

Métricas de evaluación

0,35

R^2 · validación cruzada

promedio de las 5 redes: explica el 35 % de la variación de log(salario) dentro del país

0,30–0,44

R^2 · prueba

en las 5 redes, con personas que nunca vieron

18–29 %

menos error (MAE)

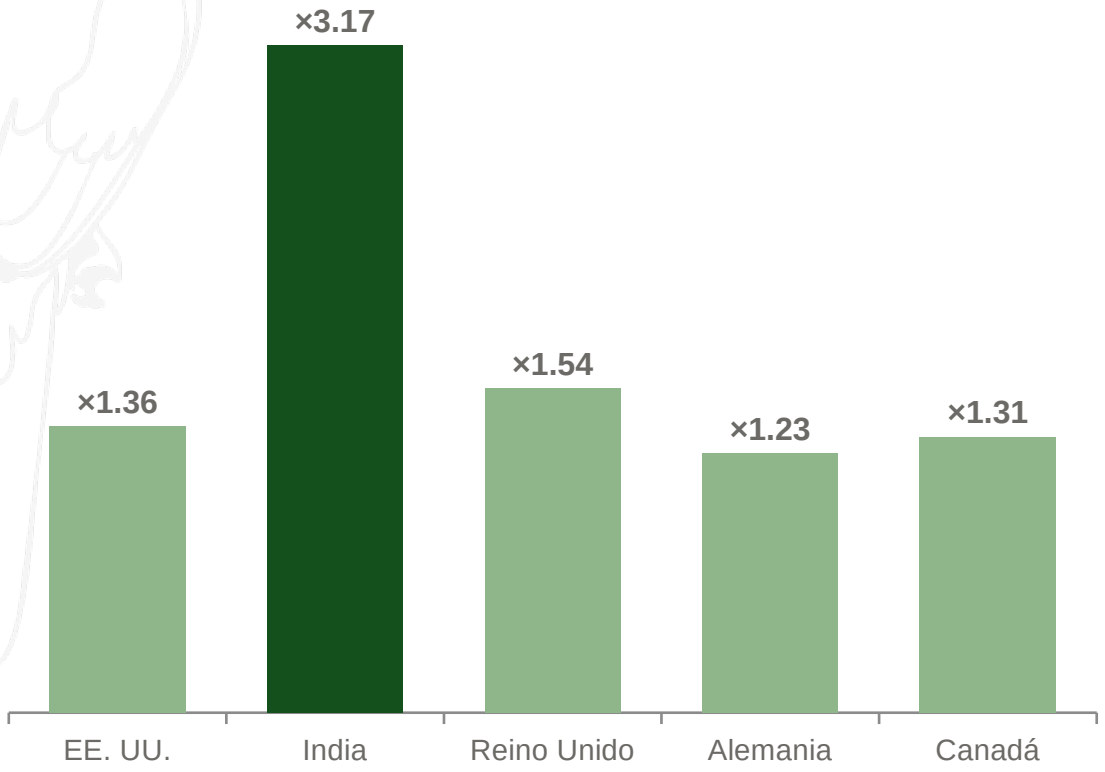
que el modelo base, que siempre predice la mediana del país

País	R^2 val. cruzada	R^2 prueba	MAE red / base (USD)
Estados Unidos	0,395	0,406	32.417 / 42.654
India	0,359	0,439	7.282 / 10.195
Reino Unido	0,385	0,302	25.570 / 31.247
Alemania	0,316	0,399	13.350 / 17.636
Canadá	0,288	0,394	14.720 / 19.524

Es regresión: Accuracy y F1-Score no aplican. La cifra de referencia es el R^2 de validación cruzada.

¿Qué cambia entre países?

Salario con 10 años ÷ salario con 1 año



La experiencia manda

Es la variable más importante en las 5 redes (importancia por permutación).

Pero no paga igual

De 1 a 10 años, el salario se triplica en India y sube solo 23 % en Alemania.

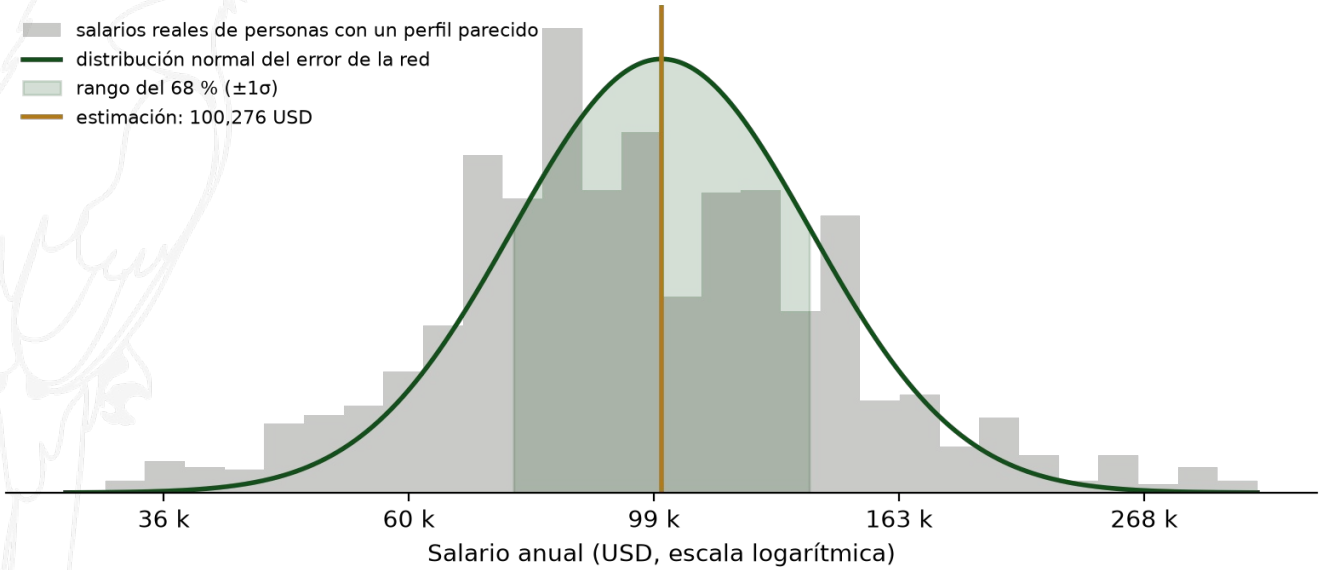
Lo segundo que más pesa

Tamaño de la empresa en India y Alemania; tipo de desarrollador en EE. UU.; tipo de empleo en Reino Unido; lenguajes en Canadá.

Cuidado al comparar

Alemania y Canadá tienen menos datos: sus resultados son menos firmes.

¿Qué tan lejos queda la estimación?



Python, 3 años, EE. UU.: la red estima 100.276 USD. Las barras grises son los salarios reales de 1.416 personas que usan Python y tienen de 1 a 5 años de experiencia.

Rango del 68 % · EE. UU.

estimación × 0,74 a × 1,36

σ robusta = 0,30 en log(salario)

País	σ	Rango 68 %	En prueba
EE. UU.	0,30	×0,74–1,36	66 %
India	0,60	×0,55–1,83	72 %
R. Unido	0,34	×0,71–1,41	64 %
Alemania	0,24	×0,78–1,28	67 %
Canadá	0,30	×0,74–1,35	73 %

El rango es honesto: entre el 64 % y el 73 % de las personas de prueba cae dentro, cerca del 68 % esperado.

Lo que nos afectó y sus consecuencias

45,5 % de salarios imputados

Consecuencia: La red habría aprendido a decir siempre 54.049 USD.

Qué hicimos: Entrenamos solo con salarios reportados.

Salarios imposibles

Consecuencia: 260 personas en EE. UU. en el tope de 2 millones: el R^2 caía a 0,05–0,11.

Qué hicimos: Regla de Tukey, país por país: se quitan 1.428.

Colombia, con pocos datos

Consecuencia: No está entre los 10 países con más salarios válidos.

Qué hicimos: Usamos los 5 países con más datos limpios.

Variables que no aportan

Consecuencia: Edad, género o satisfacción laboral solo agregan ruido.

Qué hicimos: Entran solo las que suben el $R^2 \geq 0{,}005$: 12 de 17.

5 capas, pocos datos

Consecuencia: R^2 0,349: por debajo de 3 capas (0,397) y de la lineal (0,376).

Qué hicimos: L2, dropout y early stopping; lo reportamos tal cual.

Rango demasiado optimista

Consecuencia: Con residuos de entrenamiento solo el 9 % de prueba caía en el rango.

Qué hicimos: σ con residuos fuera de pliegue: 64–73 %.

Demo en vivo: la calculadora

1. El público elige un país y un perfil: lenguajes, experiencia, empresa, estudios…
2. La red de ese país devuelve el salario estimado y su rango del 68 %.
3. «El mismo perfil en los 5 países» evalúa las respuestas con las 5 redes.
4. «¿Cómo lo calcula la red?» muestra qué neuronas se encienden en las 5 capas.

País	3 años	10 años	Crece
Estados Unidos	100.276	128.780	×1,28
India	11.951	18.237	×1,53
Reino Unido	54.559	77.590	×1,42
Alemania	59.684	69.872	×1,17
Canadá	64.419	78.532	×1,22

Perfil: Python, empresa de 10.000+ personas, tiempo completo, pregrado en sistemas, 40 h por semana (USD al año).

Otro país, otra red: el mismo perfil gana 12 k en India y 100 k en EE. UU.

Qué logramos

01

Cinco redes, una por país

Cada una explica entre el 29 % y el 40 % de la diferencia de salario dentro de su país.

02

Datos honestos

Solo salarios reportados y sin atípicos: 15.552 personas en 5 países.

03

Decisiones medidas

Variables y arquitecturas comparadas con validación cruzada; la prueba solo al final.

04

Comparación entre países

La experiencia pesa más en todos, pero paga ×3,17 en India y ×1,23 en Alemania.

¿Preguntas?

UCO
Universidad Católica de Oriente
Vigilada Mineducación

Renovación Acreditación Institucional en ALTA CALIDAD



¡Gracias!